

# Zuordnung von PSI-Messpunkten zu Gebäuden (2020–2025): Stand der Technik

## Einführung

Die Persistent-Scatterer-Interferometrie (PSI) liefert aus Zeitreihen von SAR-Satellitenbildern punktuelle Deformationsmessungen im Millimeterbereich. In dichten urbanen Gebieten treten jedoch Geometrieffekte (seitliche Radaransicht, Layover) und begrenzte Geolokalisierungsgenauigkeit von oft nur wenigen Metern auf <sup>1</sup>. Dies erschwert die **Zuordnung einzelner PSI-Punkte zu konkreten Gebäuden oder Bauwerksteilen** erheblich – benachbarte Objekte (etwa Gebäude vs. Straße oder benachbarte Gebäude) können in den PS-Daten nicht klar getrennt erscheinen <sup>1</sup>. Eine zuverlässige automatische Verknüpfung der PS-Punkte mit physischen Objekten ist jedoch entscheidend, um **bauwerksbezogene Interpretationen** (z. B. Setzungen eines bestimmten Gebäudes) vornehmen zu können <sup>2</sup>. Im Zeitraum 2020–2025 wurden verschiedene Ansätze entwickelt, um dieses Zuordnungsproblem zu lösen. Diese reichen von rein geometrischen Verfahren über unüberwachte Clustering-Methoden bis hin zu ersten KI-basierten Konzepten. Im Folgenden wird ein Überblick über den Stand der Technik gegeben, relevante Methoden werden verglichen und hinsichtlich Genauigkeit, Anwendbarkeit in dicht bebauten Städten, praktischer Umsetzbarkeit (Open-Source-Tools) sowie Interpretierbarkeit und Rechenaufwand bewertet. Anschließend wird diskutiert, welche InSAR-Daten und -Attribute sich für die Zuordnung am besten eignen, wie **Zusatzdaten** (2D-Gebäudekarten, 3D-Modelle) die Zuordnung verbessern können, und wie man Ergebnisse mangels Ground-Truth validieren kann. Abschließend werden offene Herausforderungen skizziert und Empfehlungen für praxistaugliche Ansätze gegeben, einschließlich einer tabellarischen Übersicht mit Ranking der Verfahren.

## Überblick über Methoden zur InSAR-Punkt-Clusterung

**Klassische geometrische Zuordnung:** Einfachste Verfahren ordnen PS-Punkte anhand von **Gebäudegrundrissen** oder -konturen zu. Hierbei werden alle PS innerhalb (oder in der Nähe) eines Gebäude-Polygons diesem Gebäude zugewiesen. Diese **regelbasierten Ansätze** nutzen z. B. vorhandene Katasterdaten oder OpenStreetMap (OSM). Da PS-Koordinaten ungenau sein können, werden teils Pufferzonen genutzt. Ein aktueller Ansatz verbessert dies durch **adaptive Puffer**: Hu et al. (2024) vereinfachen den Gebäudeumriss mittels konvexer Hülle und erweitern ihn um einen höhenabhängigen Abstand, um Schief lagen-Effekte zu kompensieren <sup>3</sup>. Anschließend werden PS-Punkte im Puffer per nächstem Nachbarn dem Gebäude zugeordnet <sup>3</sup>. Solche rein geometrischen Methoden sind **transparent und einfach** und erfordern keine komplexen Berechnungen <sup>4</sup>. Sie profitieren von offenen 2D-Gebäudedaten (OSM, GlobalBuildingAtlas) und sind in GIS/Python (z. B. mit Shapely/GeoPandas) gut umsetzbar. Nachteile sind mögliche Fehlzugeweisungen in engen Stadtsituationen oder bei ungenauen Konturdaten.

**Unüberwachtes Clustering (Machine Learning):** Hier werden PS-Punkte aufgrund **gemeinsamer Muster** gruppiert, ohne explizite Trainingsdaten. Ein wichtiges Kriterium ist das **Deformations-Zeitreihenverhalten**: Liegen Punkte auf derselben starren Struktur (z. B. ein Gebäudeteil), zeigen ihre PS-InSAR Zeitreihen meist hoch korrelierte Verläufe <sup>5</sup> <sup>6</sup>. Moderne Clusterverfahren nutzen dies, um **lokale PS-Gruppen** zu identifizieren. Schneider und Soergel (2021–2023) beispielsweise behandeln jeden PS als Punkt in einem hochdimensionalen Raum (Dimension = Anzahl Zeitschritte) und definieren

eine **hybride Distanzmetrik** aus zeitlicher Korrelation und räumlichem Abstand <sup>6</sup>. Durch nichtlineare Dimensionsreduktion (z.B. UMAP/t-SNE) werden die PS in einen niedrigdimensionalen Raum eingebettet und anschließend mit Dichte-basierten Algorithmen (z.B. DBSCAN) geclustert <sup>7</sup>. Die Grundannahme dabei: Punkte auf demselben Bauwerksteil bilden im Deformationsdatenraum dicht beieinander liegende Cluster <sup>6</sup>. Solche **Cluster-by-Pattern**-Ansätze identifizieren Gruppen von PS, die sich synchron verhalten, und entsprechen oft tatsächlichen Gebäudeabschnitten <sup>8</sup>. Unüberwachtes Lernen wird auch auf Merkmalsräume angewandt: Anstatt die Roh-Zeitreihen direkt zu nutzen, kann man charakteristische Features (lineare Senkungsrate, saisonale Amplitude, etc.) für jeden PS extrahieren und im Merkmalsraum clustern. Studien zeigen, dass eine **multivariate Feature-Analyse** Clustermuster deutlich besser erkennen lässt als eindimensionale Betrachtung (Verbesserung um bis zu zwei Größenordnungen in Gütekriterien) <sup>9</sup>. Unüberwachte ML-Verfahren erfordern etwas mehr Rechenaufwand und Fachwissen (z.B. Wahl der Distanzmetrik, Clusteranzahl), sind aber mit offenen Libraries (scikit-learn, PyTorch, etc.) realisierbar. Ihre **Interpretierbarkeit** ist gegeben, da die resultierenden Cluster i.d.R. physikalisch nachvollziehbaren Gruppen (z.B. ein durchgehend mit PS bedecktes Gebäudedach) entsprechen <sup>8</sup>.

**Supervised Learning und Deep Learning:** Überwachte KI-Methoden (z.B. Klassifikatoren, Deep Learning) sind für dieses spezifische Zuordnungsproblem bisher kaum etabliert. Einerseits fehlen umfangreiche **Ground-Truth-Daten**, um neuronale Netze für die Objektzuordnung von PS-Punkten zu trainieren. Andererseits sind PS-Daten unregelmäßig im Raum verteilt (kein Raster), was den direkten Einsatz von CNN-Segmentierung erschwert. Erste Forschungsarbeiten setzen Deep Learning eher bei Teilproblemen ein – z.B. bei der PS-Punktelektion aus SAR-Daten <sup>10</sup> oder zur Mustererkennung in Deformationszeitreihen (z.B. LSTM-Netze zur Detektion von Knickpunkten in Bewegungsverläufen <sup>11</sup>). Perspektivisch sind aber **Deep-Learning-Ansätze denkbar**, etwa Graph Neural Networks, die PS-Punkte und Gebäudeknoten in einem Graphen verknüpfen, oder hybride CNN-Modelle, die PS-Verteilungen als Bild darstellen. Solche Ansätze könnten räumliche und zeitliche Merkmale gemeinsam lernen. Aktuell befinden sie sich jedoch im Forschungsstadium. Die **Interpretierbarkeit** wäre hierbei ein Thema, da Black-Box-Modelle schwerer zu deuten sind – ein wichtiger Aspekt im Infrastruktur-Monitoring. Insgesamt dominieren 2020–2025 noch **klassische und unüberwachte Verfahren**, während Deep Learning für die PSI-Punkt-Zuordnung eine offene Herausforderung und Chance für zukünftige Arbeiten darstellt.

**Simulation und physikalische Modelle:** Ein ergänzender Ansatz ist die Nutzung von **ray-tracing Simulationen** mit 3D-Stadtmodellen, um potentielle Streupunkte an Gebäuden vorherzusagen. Biljecki et al. (2019) beispielsweise verwendeten ein SAR-Simulator-Tool (RaySAR) und generische 3D-Gebäudemodelle in verschiedener Detailstufe (LoD1/LoD2), um vorherzusagen, wo an Gebäudefassaden und -kanten PS auftreten müssten <sup>12</sup> <sup>13</sup>. Die echten PS aus TerraSAR-X wurden dann mit den simulierten Punktzielen abgeglichen. Dabei zeigte sich, dass einfache Klötzchenmodelle (LoD1) nur ~10% der gemessenen PS einem simulierten Streupunkt zuordnen konnten, während detailliertere Dachstrukturen (LoD2) die Match-Rate auf ~37% steigerten <sup>14</sup>. Über die Hälfte der identifizierten Streupunkte entsprachen einfachen zwei- oder dreifach-Punktreflexionen (z.B. Ecke zwischen Fassade und Boden) <sup>15</sup>. Diese Ergebnisse unterstreichen den Einfluss der Modellgenauigkeit auf die Zuordnung. Solche physikalischen Simulationsansätze bieten **tiefe Einblicke in die Streumechanismen** und können helfen, PS z.B. bestimmten Fassaden (oder sogar reflektierenden Strukturelementen) zuzuordnen. Allerdings sind sie **rechenaufwändig** und erfordern detaillierte 3D-Modelle und genaue Kenntnis der SAR-Geometrie. In der Praxis werden sie daher eher zur **Validierung und Forschung** eingesetzt als für die Routine-Zuordnung aller PS in einer Stadt.

## Bewertung und Vergleich relevanter Verfahren

Angesichts der Vielfalt an Ansätzen lohnt ein Vergleich in Bezug auf **Genauigkeit der Objektzuordnung**, **Eignung für dichte urbane Gebiete**, **Verfügbarkeit in offenen Tools**, **Interpretierbarkeit** und **Rechenaufwand**:

- **Geometrische Grundriss-Zuordnung:** Einfache polygonbasierte Zuordnung (PS wird dem nächstgelegenen Gebäudeumriss zugewiesen) ist *sehr effizient* (praktisch sofort ausführbar) und *leicht interpretierbar*. In der Praxis liefert dies eine grobe Zuordnung, die für viele Anwendungen bereits hilfreich ist. In locker bebauten Bereichen mit isolierten Gebäuden ist die Genauigkeit ordentlich. Jedoch treten in **dicht bebauten Altstädten** Probleme auf: Aufgrund der Positionsungenauigkeit können Punkte fälschlich dem falschen Nachbargebäude oder der Straße zugeordnet werden <sup>2</sup>. Ohne Berücksichtigung der Gebäudehöhe kommt es zudem vor, dass PS-Punkte an höheren Gebäudefassaden nicht innerhalb des 2D-Grundrisses liegen und so ignoriert würden. Fazit: *Hohe Interpretierbarkeit und einfache Implementierung, aber in engen Stadtsituationen limitiert in der Genauigkeit*. Viele Open-Source-GIS-Tools unterstützen diese Methode (z. B. QGIS, Python Shapely).
- **Adaptives Kontur-Matching (verbesserte Geometrie):** Fortgeschrittene geometrische Verfahren wie das adaptive **Building-Contour-Matching** nach Hu et al. (2024) adressieren die obigen Probleme. Durch Nutzung der Gebäudehöhe (aus externen Daten oder Annahmen) wird eine *inklinationsabhängige Pufferzone* um den Grundriss gelegt <sup>3</sup>. Dadurch können auch PS erfasst werden, die aufgrund der seitlichen Radaransicht einige Meter vom Gebäudegrundriss versetzt liegen. In Tests konnte diese Strategie die Anzahl richtig zugeordneter PS-Punkte um **~29% steigern** <sup>16</sup>. Die Methode ist weiterhin zügig (im Wesentlichen Geometrieoperationen) und erfordert keine komplexe KI – d.h. sie ist in Python/GIS umsetzbar und **gut interpretierbar** (Parameter wie Pufferbreite lassen sich physikalisch begründen). Für dichte Bebauung ist sie deutlich besser geeignet als starre Zuordnung, da sie Überlappungen minimiert und PS-Fehlzuordnungen reduziert. Einschränkend wirkt sich die Qualität der Eingangsdaten aus: Ungenaue Gebäudehöhen oder vereinfachte Umrisse limitieren die Genauigkeit <sup>17</sup>. Insgesamt wird dieser *regelbasierte Ansatz 2.0* in aktuellen Studien als **robuste und praxistaugliche Lösung** für stadtweite Gebäude-Monitorings gesehen <sup>4</sup>.
- **Zeitreihenbasiertes Clustering:** Unüberwachte Clustering-Algorithmen, welche PS mit ähnlichen Zeitreihenmustern gruppieren, erzielen besonders in Fällen mit differierendem Deformationsverhalten eine *hohe inhaltliche Genauigkeit*. Liegen z.B. in einem Stadtquartier manche Gebäude stabil und andere setzen sich leicht, so bilden die instabilen Gebäude jeweils eigene PS-Cluster, getrennt von den stabilen Nachbargebäuden. Selbst innerhalb großer Bauwerke können Cluster verschiedene Segmente (etwa Flügel oder einzelne Bauteile) mit unterschiedlicher Bewegung anzeigen <sup>8</sup>. Studien bestätigten, dass solche zeitreihenbasierten Cluster tatsächlich **realen Gebäudeverschiebungen** entsprechen <sup>8</sup>. Der Vorteil ist, dass *automatisch* rein aus den Daten potentielle Schadens-Hotspots oder sich bewegende Objekte erkannt werden – ohne vorherige Kenntnis der Gebäudegeometrie. Für **dicht bebaute Areale** sind diese Methoden jedoch nicht allmächtig: Wenn viele Objekte sich sehr ähnlich (z.B. alles stabil) verhalten, kann das Clustering alle Punkte zu einem großen Cluster vereinen, selbst wenn sie zu unterschiedlichen Gebäuden gehören. Daher kombinieren aktuelle Ansätze räumliche Kriterien in die Distanzmetrik, um nur *lokal* benachbarte PS hoch zu gewichten <sup>6</sup>. Der **Rechenaufwand** hängt von der Punktzahl ab – moderne Implementierungen (z.B. mit k-d-Bäumen, GPU-Berechnung für Dimensionsreduktion) ermöglichen aber auch die Verarbeitung von zehntausenden PS-Punkten. Mit Python-Toolkits (scikit-learn, hdbscan, UMAP etc.) lassen sich diese Verfahren prototypisch umsetzen. Die **Interpretierbarkeit** der Ergebnisse ist durch

Visualisierung und Abgleich mit Bauwerksdaten gegeben (Cluster können z. B. farbcodiert auf einer Karte oder einem 3D-Modell dargestellt und von Experten verifiziert werden). Allerdings sind die Verfahren selbst etwas komplexer zu erklären als rein geometrische Regeln, da z. B. ein abstrakter Merkmalsraum genutzt wird. In Summe bieten Clusterverfahren eine **hohe Genauigkeit der Objektgruppierung**, vorausgesetzt es existieren genügend signifikante Unterschiede im Deformationsverhalten oder zusätzlichen räumlichen Merkmalen.

- **3D-Modell-Fusion (z. B. mit LiDAR oder TomoSAR):** Eine weitere Kategorie sind Methoden, die **externe 3D-Datenquellen** nutzen, um PS-Punkte präziser im Raum zu verorten. Dazu zählen die Verschmelzung verschiedener Radar-Geometrien (Mehrseitenblick) und die Einbindung von Laserscanning. Ein Beispiel ist die Arbeit von Schunert & Soergel (2016), in der ein **3D-Stadtmodell** (aus LiDAR-Punktwolken gewonnen) verwendet wurde, um PS-Punktwolken mittels **Iterative-Closest-Point (ICP)**-Algorithmus an Gebäudeoberflächen anzupassen <sup>18</sup>. Damit konnten insbesondere **Fassaden-PS** korrekt einem Gebäude zugeordnet werden, was die Verknüpfung von PS-Punkten mit konkreten Bauwerksteilen deutlich verbessert hat <sup>19</sup>. Der Ansatz verlangt jedoch eine *ausreichende PS-Punktdichte*, die die Form des Gebäudes errahnen lässt – in dicht bebauten oder punktearmen Arealen ist das schwierig <sup>20</sup>. Zudem muss für jedes Gebäude (oder jeden Ausschnitt) ein ICP-Abgleich gerechnet werden, was bei großflächiger Anwendung sehr rechenintensiv wird. Ähnlich gelagert sind Ansätze, die **mehrere SAR-Orbits kombinieren**: Gernhardt et al. (2021) z. B. fusionierten TerraSAR-X Daten aus aufsteigenden und absteigenden Bahnen, um über Stereo-SAR die 3D-Position opportunistischer Streuer zu berechnen – validiert mit LiDAR erreichte man so ~20 cm Ortsgenauigkeit <sup>21</sup>. Solche Methoden erhöhen die Zuordnungsgenauigkeit drastisch, sind aber **aufwendig und datenintensiv** (erfordern mehrere Bildstapel und komplexe Optimierungen). LiDAR-gestützte Verfahren können PS-Punkte prinzipiell auch sehr gut klassifizieren bzw. Objekten zuordnen <sup>22</sup>, sind aber in der Praxis durch die begrenzte Verfügbarkeit aktueller Laserdaten und hohe Kosten nicht flächendeckend einsetzbar <sup>23</sup>. Insgesamt bieten 3D-Fusionsmethoden die *höchste physikalische Genauigkeit*, sind aber meist nur punktuell oder in Forschungsprojekten realisiert worden. Ihre Interpretierbarkeit ist hoch (man sieht buchstäblich, welcher PS auf welcher Gebäudefläche liegt), doch die **Praxistauglichkeit** für großflächiges Monitoring ist wegen der Datenanforderungen momentan moderat.

- **Baseline: rein räumliches Clustering:** Als Referenz sei erwähnt, dass einfaches Clustering nur nach PS-Koordinaten (etwa mittels DBSCAN mit Radius ~einige Meter) eine naive Lösung darstellt. Diese Gruppierung fasst PS-Punkte, die nahe beieinander liegen, zu Clustern zusammen – was in Regionen mit isolierten Bauwerken teils mit tatsächlichen Objekten korrespondiert. In komplexen Stadtgebieten versagt dies jedoch oft, da PS verschiedener enger Nachbargebäude vermischt werden, wenn deren Abstand kleiner ist als die typische Ortsungengenauigkeit. Wie oben beschrieben sind ohne zusätzliche Informationen Gebäude und Straßen-PS nicht zuverlässig unterscheidbar <sup>2</sup>. Rein räumliche Cluster sind daher **ungenau** in der Objekttrennung und nur in homogenen Szenarien sinnvoll. Ihr Nutzen liegt höchstens in der Initialisierung für andere Methoden. Aufgrund der leichten Verfügbarkeit (Clustering-Algorithmen in jeder Statistik-Software) werden sie dennoch als Basis oder Vergleich herangezogen, gelten aber nicht als Stand-der-Technik für präzise Gebäudezuordnung.

Die **Tabelle 1** bietet eine zusammenfassende Gegenüberstellung wichtiger Ansatztypen mit einer Einschätzung ihrer Praxistauglichkeit:

Ansatz	Genauigkeit	Urban-Tauglichkeit	Open-Source	Interpretierbarkeit	Rechenaufwand
<i>Geom. Zuordnung (konventionell)</i> (PS in Gebäudepolygon)	Mittel – abhängig von Gebäudedichte; potenzielle Fehlzusammenordnung in engen Vierteln <sup>2</sup>	Eingeschränkt bei dichter Bebauung	Ja (GIS, Shapely etc.)	Sehr hoch (einfache Regel)	Gering (einfache Zuordnung)
<i>Geom. Zuordnung (adaptiv)</i> (Puffer, Höhe berücksichtigen)	Hoch – deutlich verbesserte Trefferquote (+ ≈ 29 % PS zugeordnet) <sup>16</sup>	Gut auch in dicht bebauten Städten	Ja (GIS, Python)	Hoch (Regeln physikalisch begründbar)	Gering (einfache Zuordnung)
<i>Zeitreihen-Clustering</i> (hybride Distanz, DBSCAN)	Hoch – identifiziert zusammengehörige PS zuverlässig, reflektiert reale Bauwerksteile <sup>8</sup>	Hoch, wenn unterschiedliche Bewegungen vorliegen; bei völlig starren Gebieten Vorsicht	Ja (scikit-learn, PyTorch)	Mittel-Hoch (Cluster müssen gedeutet werden)	Mittel (Dimensionen reduzieren)
<i>3D-Modellabgleich</i> (LiDAR, ICP, multi-Orbit)	Sehr hoch in idealen Fällen (cm-genaue Verortung möglich) <sup>21</sup> ; aber stark datenabhängig	Mittel – in <b>sehr</b> dichter Bebauung begrenzt (PS-Dichte, Datenverfügbarkeit)	Teilweise (ICP-Algorithmen als Bibliotheken, aber benötigt 3D-Daten)	Hoch (visuell überprüfbar an 3D-Struktur)	Hoch (punktgenaue Zuordnung)
<i>Raytracing-Simulation</i> (Vorwärtsmodellierung)	Mittel – etwa 10–37 % der PS erklärbar (je nach Modell-Detailgrad) <sup>14</sup>	Eingeschränkt (vor allem Forschung, benötigt detaillierte 3D-Modelle)	Ja (RaySAR frei verfügbar)	Mittel (Ergebnisse nachvollziehbar, aber komplex)	Sehr hoch (Simulationen)

**Tabelle 1:** Vergleich verschiedener Ansätze zur PSI-Punkt-Zuordnung. Kriterien: geschätzte Zuordnungsgenauigkeit, Eignung für dichte urbane Gebiete, Verfügbarkeit als Open-Source-Tool, Interpretierbarkeit und Rechenaufwand. Quellen: Ergebnisse und Bewertungen basierend auf Literatur <sup>1</sup> <sup>16</sup> <sup>8</sup> <sup>14</sup> und Einschätzungen der aktuellen Forschungslage.

## Nutzung von InSAR-Attributen und Zeitreihen

Für die erfolgreiche Zuordnung von PS-Punkten zu Objekten sind **geeignete InSAR-Attribute** entscheidend. Neben der reinen 2D-Position (X,Y) bieten die PS-InSAR-Daten weitere Merkmale, die Hinweise auf die zugehörigen Objekte geben:

- **Deformationsgeschwindigkeit (vel)**: Die mittlere jährliche Geschwindigkeitsrate eines PS (z. B. in mm/Jahr) ist ein zentrales Attribut. Gebäude, die sich unterschiedlich schnell setzen oder heben, lassen sich darüber unterscheiden. In einer Stadt können PS-Punkte mit ähnlicher Geschwindigkeit gruppiert werden, was häufig einem gemeinsamen Ursachemechanismus

entspricht (etwa gleiche Untergrundsenkung). Allerdings kann ein ähnliches Geschwindigkeitsniveau auch bei verschiedenen Objekten auftreten (z. B. mehrere Gebäude erfahren alle  $\sim 2$  mm/Jahr durch regionalen Grundwasseranstieg). Daher ist **vel** allein oft zu grob für die punktgenaue Zuordnung.

- **Komplette Zeitreihe:** Die Nutzung der vollständigen PS-Zeitserien gilt als Königsweg, um **charakteristische Deformationsmuster** zu erkennen. Punkte auf demselben Bauwerk zeigen oftmals nahezu identische Zeitreihenverläufe (im Idealfall sind sie nur um einen konstanten Offset unterschiedlicher Höhe verschoben) <sup>5</sup>. Korreliert man die Zeitreihen zweier PS, erhält man ein Maß ihrer Verhaltensähnlichkeit. Eine hohe Korrelation deutet stark auf dasselbe Objekt hin <sup>5</sup>. Moderne Clusterings nutzen diesen Ansatz (siehe oben hybrider Abstand) und damit *implizit* die volle Zeitreiheninformation. Darüber hinaus erlauben Zeitreihen die Identifikation komplexerer Muster: z. B. nicht-lineare Bewegungen oder episodische Sprünge (eventuell infolge von Bauarbeiten oder Erdbeben). Methoden, die Zeitreihen direkt vergleichen (z. B. Dynamic Time Warping oder Spektralanalysen), können PS nach solchen Mustern gruppieren. Zhu et al. (2018) und Costantini et al. (2018) etwa führten eine Clusterung der COSMO-SkyMed Deformationszeitreihen durch, um unterschiedliche *temporale Deformationsmoden* im Datensatz aufzudecken <sup>8</sup>. Ein Nachteil der Vollzeitreihennutzung ist das Rauschen und die Datenlücken, die den direkten Vergleich erschweren können – daher der oft genutzte Schritt der Merkmalsextraktion.
- **Saisonale Parameter:** Viele PS-InSAR-Auswertungen passen ein Modell aus linearer Trend + saisonalem (jährlichem) Signal an die Zeitreihen an. Daraus ergeben sich **Parameter wie Amplitude und Phase der saisonalen Schwingung**. In urbanen Szenarien kann dies relevant sein: Massive Gebäude mit thermischer Ausdehnung zeigen oft jahreszeitliche Höhenänderungen (z. B. im Sommer etwas höher wegen Hitzeausdehnung). Ein PS auf einem solchen Dach hätte eine merkliche jährliche Komponente, während ein PS auf dem Boden nahebei diese evtl. nicht hat. So könnten *saisonale Merkmale* helfen, PS auf Gebäuden von jenen am Boden zu trennen. Ebenso könnten alle Punkte auf demselben Gebäude eine ähnliche Phasenlage der saisonalen Schwingung haben. Bislang wird dies selten isoliert zur Clusterung herangezogen, doch als Teil multivariater Feature-Vektoren (Trend, Amplitude, etc.) fließt es in neueren Studien ein <sup>9</sup>. Masciulli et al. (2025) fanden, dass eine multivariate Betrachtung (Kombination mehrerer Zeitreihen-Features) univariate Analysen übertrifft <sup>9</sup> – was impliziert, dass gerade die Mischung aus Trend- und Saisonmerkmalen die besten Cluster-Ergebnisse lieferte.
- **Kohärenz und Qualitätsmaße:** Jeder PS-Punkt besitzt Qualitätsindikatoren wie die **Phasenkohärenz** oder die Standardabweichung der geschätzten Geschwindigkeit. Diese sagen zwar nichts direkt über das Objekt aus, werden aber genutzt, um unreliable Punkte auszufiltern. Für die Zuordnung nutzt man z. B. nur PS mit ausreichender Kohärenz, um Fehlgruppierungen durch verrauschte Punkte zu vermeiden. Manche Verfahren könnten Qualitätsmaße auch gewichten: etwa Cluster nur aus Punkten zu bilden, die alle eine hohe Kohärenz teilen (was wahrscheinlich strukturelle Dauerstreuer sind). Insgesamt dienen diese Attribute eher als *Filter* denn als Clusterkriterium.
- **Höhe (height):** Die absolute Höhe eines Streupunkts über Grund (oder über dem Referenzellipsoid) wäre ein äußerst wertvolles Attribut für die Objektzuordnung – beispielsweise um zu unterscheiden, ob ein PS auf dem Dach (hoch) oder auf Straßenniveau (niedrig) liegt. Allerdings ist die Höhe bei Standard-PSI auf einen externen DEM-Bezug angewiesen und meist ungenau. Bei Hochauflösungs-SAR (TerraSAR-X Spotlight) kann man in urbanen Gebieten mit Dual-Track oder TomoSAR-Ansätzen die Höhe einzelner Streuer bestimmen <sup>21</sup>. Falls verfügbar,

lässt sich **height** hervorragend nutzen: Liu et al. (2023) etwa extrahierten alle PS *innerhalb* eines Gebäudegrundrisses und betrachteten den **Höhenunterschied** zu PS *außerhalb*, um echte Gebäude-PS herauszufiltern <sup>24</sup>. Ein PS, das deutlich höher liegt als die Umgebung, gehört vermutlich zu einem Gebäude (nicht zum Boden). Höhe kann also als zusätzliches Kriterium im Zuordnungsalgorithmus dienen – sei es durch simple Schwellen (z.B. >5m über Boden -> Gebäude) oder als Merkmal in einem ML-Modell. Wo keine direkte PS-Höhenschätzung möglich ist, können Gebäudehöhenmodelle proxyweise genutzt werden (siehe nächster Abschnitt zur Datenfusion). Insgesamt ist die **3D-Information** ein Schlüsselfaktor: Sie trennt vertikal gestapelte Objekte (Brücke vs. Straße darunter, Hochhaus vs. Vorgarten) die in 2D und sogar in Deformationsverhalten ähnlich sein könnten.

- **Weitere abgeleitete Kennwerte:** In Forschungsansätzen werden auch spezielle Indizes vorgeschlagen, um PS-Gruppen auf Objekte zu beziehen. Ein Beispiel ist der *InSAR Non-Uniform Settlement Index* (NUSI) aus Liu et al. (2023) <sup>25</sup> <sup>26</sup>, der die Heterogenität der Senkung innerhalb eines Gebäudes quantifiziert und zur Bewertung von alternden Gebäuden nach Tunnelbau eingesetzt wurde. Solche Indizes kombinieren mehrere PS-Informationen (Höhenlage, Deformationsgradienten etc.) zu einem einzigen Wert pro Gebäude. Für die eigentliche Clusterung spielen sie weniger eine Rolle, wohl aber für die **Bewertung der zugeordneten PS-Menge** je Objekt (z.B. um zu entscheiden, ob ein Gebäude als „unregelmäßig verformt“ gelten soll).

Zusammenfassend eignen sich für die Zuordnung insbesondere **räumliche Koordinaten, Deformationszeitreihen bzw. daraus gewonnene Merkmale (Geschwindigkeit, Beschleunigung, saisonale Amplitude)** und – wo möglich – **Höheninformationen** der Scatterer. Die Kombination dieser Attribute verspricht die höchste Trennschärfe. Moderne Verfahren bevorzugen multivariate Ansätze: statt nur auf einen Wert zu schauen, wird ein Feature-Vektor aus mehreren InSAR-Attributen gebildet und im Zusammenwirken analysiert <sup>9</sup>. Damit können unterschiedliche Aspekte der PS-Eigenschaften (räumlich und zeitlich) gemeinsam genutzt werden, um Punkte zum selben Objekt zu gruppieren.

Eine Sonderbetrachtung verdient der **Einsatz expliziter Zeitreihenmethoden**: Einige Arbeiten nutzen nicht nur statische Merkmale, sondern betrachten z.B. die Fourier-Spektren der PS-Zeitreihen, Clustering von Wavelet-Koeffizienten oder identifizieren *Änderungspunkte* in den Verläufen (changepoint detection) mittels ML, um PS mit ähnlichen Veränderungen zusammenzufassen. Diese gehen über den linearen Trend hinaus und könnten insbesondere *transiente Effekte* erkennen (z.B. alle PS, die einen Knick im Jahr X aufweisen → möglicherweise durch ein Bauereignis an einem Gebäude). Solche Zeitreihen-Analysen sind jedoch eher auf die Detektion von Ereignissen ausgerichtet als auf die statische Objektzuordnung, ergänzen aber das Methodenspektrum.

## Datenfusion mit Gebäudepolygonen und Höhenmodellen

Die Einbeziehung von **Zusatzdaten** der städtischen Bebauung ist ein zentraler Hebel, um die Zuverlässigkeit der PS-Zuordnung zu steigern. Insbesondere **2D-Gebäudekarten** (Polygone) und **3D-Gebäudemodelle oder Höheninformationen** (LOD1-Modelle) haben sich als nützlich erwiesen:

- **Gebäudepolygone als Filter und Label-Quelle:** Offene Datensätze wie OSM oder der *Global Building Atlas* (GBA) bieten für viele Regionen flächendeckende Gebäudegrundrisse. Diese können direkt genutzt werden, um PS-Punkte grob zu gruppieren: Punkte, die innerhalb eines Polygons liegen, werden dem entsprechenden Gebäude-ID zugeordnet. Dies ist oft der erste Schritt einer Datenfusions-Pipeline – quasi eine *Vorsegmentierung des Raumes*. Wie bereits diskutiert, reicht dies allein wegen der Geolokationsfehler nicht aus. Daher werden Polygone

modifiziert oder flexibel gehandhabt (z. B. mittels Pufferzonen). Eine raffinierte Methode ist das **Reverse Geocoding in SAR-Geometrie**: Schneider & Soergel (2021) projizierten die 2D-Gebäudegrundrisse ins **Radar-Schrägaufnahmesystem**, um exakt vorherzusagen, wo ein Gebäude aus Sicht des Satelliten erscheint <sup>27</sup>. Dadurch konnten sie PS-Punkte wesentlich genauer dem richtigen Gebäude zuordnen, als es in der Kartenprojektion möglich wäre <sup>28</sup>. Die Idee dahinter: statt anzunehmen, dass jeder PS „über seinem Gebäude“ liegt, berücksichtigt man den tatsächlichen Blickwinkel und *verschiebt die Gebäudekontur entsprechend in der SAR-Ebene*. So eine geometrische Transformation der Polygone erfordert Kenntnisse der SAR-Orbitparameter und der Geländehöhe, ist aber mathematisch nachvollziehbar und kann automatisiert werden. Allgemein dienen Gebäudefootprints auch als **logische Gruppierungseinheiten**: Man kann z. B. für jedes Gebäude alle nahegelegenen PS sammeln und diese als Einheit einem Clustering unterziehen (anstatt global zu clustern). Dies stellt sicher, dass keine Cluster Punkte aus völlig verschiedenen Gebäuden zusammenfassen. Viele Studien zu Bauwerksüberwachung (z. B. in der Strukturüberwachung nach Tunnelvortrieb) nutzen Gebäude-Vektordaten, um *Monitoring-Punkte vorab pro Gebäude zu separieren* <sup>29</sup>. Oft geschieht dies allerdings sehr simpel („alle PS in Polygongrenzen“), was wie erwähnt nicht immer zuverlässig ist <sup>30</sup>. Dennoch bilden Gebäudedaten eine **unverzichtbare Grundlage**, um PSI-Ergebnisse in den städtischen Kontext einzubetten.

- **Integration von Gebäudehöhen (LOD1)**: Kenntnis über die Gebäudehöhe oder -stöcke (etwa aus CityGML-LoD1 Modellen oder dem GlobalBuildingAtlas) ermöglicht es, die **vertikale Ausdehnung** ins Zuordnungsverfahren einzubeziehen. Praktisch kann man dadurch die oben genannten Pufferzonen *datengesteuert* setzen: z. B. Pufferbreite = Höhe \*  $\tan(\text{Incidence-Angle})$  oder ähnliche Heuristiken. Im Ansatz von Hu et al. (2024) wurde genau dies als „adaptive buffer“ umgesetzt, wobei hohe Gebäude eine größere Zuordnungszone erhalten als niedrige <sup>3</sup>. Auch eine **Segmentierung sehr langer Gebäude** wird durch Höhenwissen unterstützt: Bei ausgedehnten Gebäudekomplexen, die z. B. Innenhöfe oder komplexe Formen haben, kann man deren Grundriss anhand von Höhen- oder Stockwerkangaben aufteilen (z. B. Flügel A = 10 Stockwerke, Flügel B = 5 Stockwerke, etc.). Das verbessert die Treffsicherheit der convex-hull-Ansätze, da ein großer Gebäudepolygon in mehrere konvexe Segmente zerlegt werden kann, die jeweils homogener sind <sup>31</sup>. LOD1-Daten (quasi extrudierte Grundrisse mit mittlerer Höhe) sind inzwischen global verfügbar <sup>32</sup> und relativ leicht mit PS-Daten zu verknüpfen. Besonders deutlich zeigt sich der Nutzen in der Raytracing-Studie: Dort führte der Sprung von LoD1 zu LoD2 dazu, dass plötzlich viele Streupunkte an höheren Fassadenteilen korrekt vorhergesagt und zugeordnet werden konnten <sup>33</sup>. Ohne Höheninformation wären diese der falschen Ebene (Boden) zugeordnet geblieben. **Fazit**: Das Hinzuziehen von Gebäudehöhen erhöht die geometrische Treffsicherheit und sollte – wo immer verfügbar – genutzt werden. Tools wie der GlobalBuildingAtlas bieten diese Informationen offen an, sodass auch breite Anwendungen möglich sind.

- **Hochdetaillierte 3D-Modelle (LOD2+)**: Noch einen Schritt weiter geht die Nutzung vollständiger 3D-Modelle mit Dachformen (LOD2) oder gar Fassadendetails (LOD3). Solche Daten stammen meist aus Airborne Laserscanning oder CityGML-Modellen größerer Städte. Ihr Vorteil ist, dass man PS-Punkte direkt in 3D **gegen das Modell matchen** kann. Der ICP-Algorithmus von Schunert & Soergel (2016) ist ein Beispiel: Hier wurde ein aus Laserscandaten generiertes 3D-Fassadenmodell genommen und die PS-Punktwolke (TerraSAR-X PS) so transformiert, dass sie optimal am Modell liegt <sup>18</sup>. Ergebnis: PS ließen sich bestimmten Gebäudeseiten und -elementen direkt zuordnen, insbesondere an klaren Strukturen wie planen Fassadenflächen <sup>19</sup>. Einschränkung ist, dass PSI-Punktwolken trotz hoher Auflösung oft lückenhaft und verrauscht sind – ein starres ICP funktioniert nur, wenn genug geometrische Struktur in den Punkten vorhanden ist (z. B. dichte Punkte entlang einer Dachkante). In **sehr dicht bebauten Gebieten**

mit komplexer Geometrie und wenigen PS pro Objekt musste man in Schunerts Ansatz die Auswahlkriterien lockern, was wiederum die Deformationsgenauigkeit beeinträchtigte <sup>20</sup>. Dennoch zeigen diese Versuche, dass 3D-Modelle eine exzellente Referenz sein können: Im Prinzip lässt sich für jeden PS prüfen, zu welchem Modell-Oberflächenstück er den minimalen Abstand hat – damit hätte man eine direkte Zuordnung. Die Herausforderung liegt in der Genauigkeit: Modellfehler oder GPS-Unschärfen können eine falsche Oberfläche als „nächstes“ erscheinen lassen. Deshalb wird teils iterativ optimiert (ICP). Eine weitere Datenquelle im 3D-Kontext ist **LiDAR-Punktwolken** selbst: Anstatt erst ein polygonales Modell abzuleiten, kann man PS direkt mit Original-LiDAR-Punkten matchen. Forscher haben z.B. PS-Höhen über die Schnittpunkte ihrer Fehlerellipsoide mit einem dichten Laserscan optimiert <sup>34</sup>. LiDAR liefert zudem Klassifizierungen (z.B. Gebäudepunkt, Bodenpunkt), die man auf PS übertragen könnte. Allerdings bleibt der **Datenzugang** der limitierende Faktor: Städte mit offenen LiDAR-Daten (z.B. einige in den USA oder Europa) erlauben solche Fusionen, anderswo muss man auf global verfügbare, aber weniger detaillierte Modelle zurückgreifen.

- **Andere Zusatzdaten:** Neben direkten Gebäudedaten können auch *indirekte Informationen* genutzt werden. Straßen- und Katasterpläne ermöglichen z.B. das Einziehen logischer Grenzen: Liegt ein PS-Punkt auf der anderen Seite einer Straße als ein Gebäude, gehört er vermutlich nicht zu diesem Gebäude (auch wenn die Distanz klein ist). Solche **Constraints** können ins Clustering einfließen, indem man Gruppen, die z.B. über Straßen hinweggehen, als ungültig verwirft. Ebenso können Satelliten- oder Luftbilder zur Plausibilisierung beitragen: Sichtbare Schäden oder Merkmale auf einem Gebäude könnten mit PS-Clustern abgeglichen werden. Ein innovativer Ansatz war die Verwendung schräger **optischer Bilder**: Schack & Soergel (2015) gruppieren PS an regelmäßig strukturierten Hochhausfassaden und nutzten dann Graph-Matching, um diese Gruppen ihrem entsprechenden **Stockwerk** und Fensterreihe in einem Schrägluftbild zuzuordnen <sup>35</sup>. Dies ermöglichte eine sehr greifbare Verortung (z.B. „dieser PS stammt von der 5. Etage, 3. Fensterachse der Fassade“). Diese Art der *multisensoralen Datenfusion* ist zwar komplex, zeigt aber die Möglichkeiten auf, PS-Daten mit **BIM (Building Information Modeling)** oder bildgebenden Daten zu verknüpfen. Insgesamt gilt: Je mehr externe Informationen über die urbane Umgebung vorliegen, desto besser lässt sich der **Bezug der PS-Punkte zur realen Welt** herstellen. Dabei muss immer auf die räumliche Bezugnahme geachtet werden (z.B. durch Transformation in ein gemeinsames Koordinatensystem oder SAR-Geometrie). Die derzeit praktikabelsten Zusatzdaten sind 2D-Baupläne und grobe Höhenmodelle, da sie global verfügbar sind – detaillierte 3D-Modelle bleiben ein zusätzlicher Bonus in technisch fortgeschrittenen Anwendungen.

## Validierungsmethoden ohne Ground Truth

Die Verifikation der Zuordnungsergebnisse stellt eine Herausforderung dar, da in der Regel keine „wahre“ Zuordnung (Ground Truth) für jeden PS-Punkt existiert. Dennoch haben Forscher verschiedene **Validierungsstrategien** entwickelt, um die Plausibilität und Güte der Zuordnung zu bewerten:

- **Visuelle Inspektion und Expertenbewertung:** Die einfachste Methode ist die kartografische Darstellung der zugeordneten PS (z.B. unterschiedliche Farben pro Gebäude) über Luftbildern, Stadtplänen oder 3D-Stadtmodellen. Fachexperten (z.B. Bauingenieure, Geotechniker) können dann anhand ihres Wissens beurteilen, ob die Clustereinteilung sinnvoll erscheint. Beispielsweise lässt sich prüfen, ob alle PS einer Gruppe tatsächlich auf demselben Gebäude liegen oder ob augenfällige Fehlzuordnungen (PS von Nachbardächern in einer Gruppe) vorkommen. In vielen Studien fließt eine solche **qualitative visuelle Prüfung** ein, oft untermauert durch Beispiele. Schneider et al. (2021) etwa zeigen 3D-Visualisierungen, in denen PS-Cluster auf den Laserpunktwolken der Gebäude abgebildet sind, um die Segmente

nachvollziehbar zu machen <sup>36</sup>. Diese Methode ist subjektiv, aber effektiv, um grobe Fehler aufzudecken.

- **Konsistenz zwischen unabhängigen Datensätzen:** Eine robuste Validierungsmöglichkeit ist der Abgleich von Ergebnissen aus *verschiedenen InSAR-Datensätzen*. Wenn z.B. für dasselbe Gebiet sowohl Ascending- als auch Descending-Orbit PS-Daten vorliegen (oder verschiedene Satelliten), kann man prüfen, ob die Zuordnungen übereinstimmen. Hu et al. (2024) wählten diesen Ansatz: Sie wendeten ihre Zuordnungsstrategie auf PS-Punkte aus *zwei unterschiedlichen TerraSAR-X Bahnen* an und verglichen, inwieweit dieselben Gebäude aus beiden Blickwinkeln PS zugeordnet bekamen <sup>37</sup>. Ein signifikanter Zugewinn an Matches (29% mehr) und die Übereinstimmung der Ergebnisse für beide Orbits gaben Hinweise darauf, dass die Zuordnung korrekt und nicht zufällig war <sup>16</sup>. Ähnlich kann man PS von Sentinel-1 mit solchen von z.B. Cosmo-SkyMed vergleichen – obwohl die Punktdichte unterschiedlich ist, sollten größere Gebäudebewegungen in beiden Datensätzen an ähnlichen Orten detektiert werden. Eine konsistente Objektzuordnung über **mehrere unabhängige Messungen** stärkt das Vertrauen in die Methode.
- **Vergleich mit externen Messungen:** Wo verfügbar, können **GNSS-Sensoren, Nivellements oder Neigungsmesseinrichtungen** an Gebäuden herangezogen werden. Zwar gibt es selten flächendeckend solche Daten, aber für einzelne Bauwerke (z.B. überwachte Brücken, Hochhäuser mit eingebauten Sensoren) kann man prüfen, ob die PS, die dem Objekt zugeordnet wurden, ähnliche Deformationen anzeigen wie die in-situ Sensoren. Wenn z.B. ein Gebäude-GNSS eine Subsidenz von 5 mm/Jahr misst und der gemittelte Trend der zugeordneten PS ebenfalls ~5 mm/Jahr ist, untermauert dies die korrekte Auswahl der Punkte. Abweichende PS könnten dagegen Fehlzuordnungen oder Rauschen sein. Auch **geodätische Aufmaße** (wie Laser-Scan zu zwei Zeitpunkten) könnten als Referenz dienen: Hat sich ein Gebäude laut LiDAR um X mm verzogen, sollte die PS-Gruppe ähnliches zeigen.
- **Statistische Konsistenz und interne Qualitätsmaße:** In Abwesenheit externer Daten greifen einige Validierungsmethoden auf statistische Gütekriterien zurück. Ein Beispiel ist der **Silhouettenkoeffizient** oder der **Davies-Bouldin-Index** aus der Clusteranalyse, die messen, wie gut separiert die gefundenen Cluster im Merkmalsraum sind. Masciulli et al. (2025) entwickelten z.B. einen angepassten dichtebasierten Score namens *MLRD*, um die Qualität von Clustern in dünn verteilten geodätischen Daten zu beurteilen <sup>9</sup>. Solche Kennzahlen können helfen, verschiedene Parametereinstellungen (z.B. Clusteranzahl) zu vergleichen oder die Wirkung zusätzlicher Features zu quantifizieren, ohne dass Ground Truth vorhanden ist. Wichtig ist, dass ein hoher interner Score zwar auf gut getrennte Cluster hindeutet, aber nicht automatisch bedeutet, dass diese den realen Objekten entsprechen – die Validität muss immer auch fachlich plausibel sein. Nichtsdestotrotz sind **interne Validierungskriterien** ein wertvolles Werkzeug, um z. B. aus mehreren Clustering-Varianten die beste auszuwählen.
- **Plausibilisierung mittels Regeln:** Man kann gewisse **Erwartungsregeln** aufstellen und prüfen, ob die Zuordnung damit übereinstimmt. Ein Beispiel: Man erwartet, dass PS, die einem Gebäude zugeordnet sind, sich innerhalb der räumlichen Ausdehnung dieses Gebäudes befinden (eventuell zuzüglich gewissem Puffer). Wenn nun ein PS, der weit weg liegt, trotzdem als zum Gebäude gehörig gekennzeichnet wurde, flaggt dies einen Fehler. Solche Checks (Distanzcheck, Höhencheck – z. B. PS-Höhe sollte ungefähr Gebäudehöhe sein) können automatisch über alle Zuordnungen durchgeführt werden. Sind Verstöße selten oder erklärbar, spricht das für die Qualität. Ebenso könnte man prüfen, ob benachbarte Gebäude *unterschiedliche* PS-Gruppen erhalten haben – falls nicht (ein Cluster erstreckt sich über zwei Gebäude, die eigentlich getrennt sein sollten), wäre das ein Hinweis auf Übergreifen. In der Hu et al. (2024) Studie wurde erwähnt,

dass die neu hinzugekommenen PS durch ihren Ansatz eine klare **lineare und aggregierte Anordnung entlang der Gebäude** zeigten <sup>17</sup>, was im Gegensatz zur Verteilung vor der Korrektur stand. Dieses Muster (PS ordnen sich an Gebäudekanten/linien) deutet validierend darauf hin, dass die Punkte nun wirklich Gebäudestrukturen folgen.

- **Synthetische Tests:** In der Forschung werden gelegentlich synthetische PS-Daten generiert, um Algorithmen zu testen. Dabei werden z. B. virtuelle Städte oder Gebäudemodelle angenommen, dafür PS-Punkte simuliert (inklusive Rauschen und Fehlern) und dann geschaut, ob der Zuordnungsalgorithmus die PS dem richtigen „virtuellen“ Gebäude zuweist. Solche Simulationen können systematisch Schwachstellen aufdecken (z. B. ab welcher Positionsungenauigkeit die Methode versagt, oder wie dicht zwei Gebäude stehen dürfen). Allerdings ist der Transfer auf reale Daten immer mit Vorsicht zu genießen, da echte Städte komplexer sind. Nichtsdestotrotz bilden *kontrollierte Simulationen* einen wichtigen Teil der Validierung neuer Methoden in Veröffentlichungen.

Ohne Ground Truth stützt man sich also auf eine **Mischung aus Konsistenzprüfungen, Experteneinschätzungen und indirekten Vergleichen**. Oft werden mehrere Strategien kombiniert: z. B. zunächst ein visueller Check, dann die Übereinstimmung zwischen Asc/Desc-PDatensätzen untersucht, und schließlich interne Clusterkennzahlen berechnet, um ein umfassendes Bild zu erhalten. Letztlich gilt, dass eine vollständige quantifizierbare Validierung schwierig ist – viele Arbeiten begnügen sich daher mit Fallstudien, in denen überzeugend dargelegt wird, dass die Zuordnungen schlüssig sind (z. B. durch Detailanalyse einzelner Gebäude). In Zukunft könnten **Crowdsourcing** (z. B. Abgleich mit Google Street View: sieht man an der PS-Position ein geeignetes Streuobjekt am Gebäude?) oder **KI-unterstützte Bildauswertung** helfen, Ground Truth zu verbessern, doch derzeit bleibt dies eine offene Aufgabe.

## Offene Herausforderungen und Forschungslücken

Trotz erheblicher Fortschritte seit 2020 bleiben bei der Zuordnung von PSI-Punkten zu urbanen Objekten mehrere **ungelöste Probleme** und Forschungsfragen bestehen:

- **Auflösung und Positionsgenauigkeit:** Die begrenzte Geolokationsgenauigkeit der PS-Punkte ist nach wie vor das Grundproblem. Auch modernste Ansätze können diese nur teilweise kompensieren. Die Frage bleibt offen, wie man *sub-Meter-Genauigkeit* breitflächig erreichen kann, ohne auf dichte externe Referenzen (wie Eckreflektoren oder LiDAR) angewiesen zu sein. Neue Satellitenmissionen mit höherer Auflösung (Capella Space, Iceye) und Multi-Viewing (Tandem-L konstellation) könnten hier helfen, aber es bedarf auch algorithmischer Innovationen, um die Fülle an Daten in bessere Koordinaten umzusetzen. **Multi-Geo-Daten-Fusion** (Kombination von GNSS, optischen Bildern und InSAR) ist ein möglicher Weg, der aber noch erforscht werden muss.
- **Dichte urbane Bebauung:** In historischen Innenstädten mit engem Nebeneinander von Gebäuden, schmalen Gassen und vielen reflektierenden Objekten stoßen die bestehenden Methoden an Grenzen. PS von verschiedenen Objekten sind hier teils *untrennbar vermischt*. Layover führt dazu, dass ein Radar-Rückstreuer Signale von mehreren physisch getrennten Strukturen enthält. Eine offene Frage ist, wie man **solche vermischten Streusignale entwirren** kann. Die klassische PSI filtert verteilte Scatterer größtenteils weg, fokussiert also auf dominante PS – aber diese dominanten können z. B. an einer Gebäudekante entstehen, wo zwei Gebäude zusammentreffen. Hier könnten *tomographische Verfahren* (TomoSAR) oder KI-Methoden zur Streuscheidentrennung (z. B. auf Basis unterschiedlicher Frequenzbänder oder Polarisationen)

künftig helfen. Ebenso ist unklar, wie man Algorithmen robust macht gegen Fehlzuweisungen in solchen Szenarien – derzeit erfordern extreme Fälle manuelle Nachkontrolle.

- **Zeitlich veränderliche Strukturen:** Gebäude sind nicht immer starre Objekte – Umbauten, Anbauten oder Schäden können die Streueigenschaften ändern. Ein PS-Cluster, das heute ein Gebäude repräsentiert, könnte in fünf Jahren teilweise verschwunden sein (z.B. durch Abriss einer reflektierenden Fassade) oder neue PS sind hinzugekommen. Die **Dynamik der Streuerzuordnung** über lange Zeiträume ist kaum untersucht. Hier stellen sich Fragen wie: Sollte ein Algorithmus „vergessen“ können, wenn PS nicht mehr zum Objekt gehören? Kann man pro Gebäude eine Historie der PS-Punkte pflegen und automatisch erkennen, wenn z.B. aufgrund eines Neubaus andere Reflexionspunkte dominieren? Solche zeitlichen Aspekte der Zuordnung könnten mittels *Change-Detection* und Tracking-Algorithmen adressiert werden – ein Feld, das noch offen ist.
- **Generalisierung auf andere Objekttypen:** Bisher liegt der Fokus stark auf Gebäuden. **Andere urbane Strukturen** wie Brücken, Dämme, Straßenabschnitte, Pipelines etc. könnten ebenfalls PS-Träger sein, aber die Zuordnungsmethoden dafür sind weniger ausgereift. Brücken etwa haben oft bestimmte PS an Pfeilern oder Widerlagern – die Zuordnung könnte hier anders (eher längs der Brücke) erfolgen als bei flächigen Gebäuden. Eine offene Herausforderung ist die Entwicklung universeller oder an Objekttypen anpassbarer Verfahren. Denkbar sind hier *objektspezifische Modelle* (z.B. bekannte Brückenform) oder Trainingsdaten, um ML-Methoden speziell auf Brückenpunkte zu optimieren. Die Übertragbarkeit der aktuellen Methoden von Gebäuden auf Infrastruktur und vice versa bedarf weiterer Forschung.
- **Integration von KI und Interpretierbarkeit:** Sollten Deep-Learning-Modelle in Zukunft zur PS-Zuordnung eingesetzt werden, stellt sich die Frage der **Nachvollziehbarkeit**. Infrastrukturverantwortliche verlangen verständliche Ergebnisse – ein rein neuronales Modell, das eine Zuordnung ausspuckt, ohne Gründe anzugeben, wäre schwer akzeptabel. Forschungsbedarf besteht darin, *erklärbare KI-Methoden* zu entwickeln, die z.B. anhand von Attention-Mechanismen zeigen, welche Features (Zeitreihenabschnitte, Nachbarschaftsbeziehungen) zur Entscheidung geführt haben. Ebenso müssen Wege gefunden werden, KI-Methoden mit wenig gelabelten Daten zu trainieren – z.B. *semi-supervised* mit Nutzung von OSM-Daten als schwache Labels.
- **Validierung und Benchmarking:** Wie oben diskutiert, fehlt oft Ground Truth. Ein Desiderat ist die Schaffung von **Benchmark-Datensätzen** für die wissenschaftliche Community. Das könnte z.B. ein Stadtgebiet sein, in dem durch unabhängige Messungen (Laserscanning, Vermessung) die genaue Gebäudedefinition und PS-Position bekannt ist, um Zuordnungsergebnisse quantitativ zu prüfen. Bislang gibt es kein etabliertes Benchmark hierzu, was den Fortschritt verifizierbarer Methoden hemmt. Eine Forschungsfrage ist auch, wie man *automatisch* Ground-Truth-ähnliche Daten generieren kann – etwa durch Simulation realistischer Stadt-Szenarien mit bekannten Parametern. Solche synthetischen Städte könnten zum Testfeld für Algorithmen werden, aber ihre Repräsentativität ist kritisch.
- **Kombination von Ansätzen:** Viele bestehende Arbeiten betrachten jeweils einen Ansatz. Eine offene Möglichkeit ist, **Methoden hybrider zu kombinieren**: z.B. erst geometrisches Matching durchführen, dann verbleibende unzugeordnete PS mit Clustering auffangen, oder parallele Nutzung mehrerer Kriterien (Ensemble-Ansätze). Wie sich solche Multi-Step- oder Ensemble-Methoden schlagen, ist noch kaum untersucht. Eventuell kann dadurch die Fehlerrate weiter gesenkt werden, indem verschiedene Algorithmen sich gegenseitig validieren (Stichwort: consensus clustering).

- **Rechenaufwand und Skalierbarkeit:** Mit steigender Verfügbarkeit von PSI-Daten (z.B. nationale Deformationsdienste mit Milliarden von PS-Punkten) wird die Skalierbarkeit zum Thema. Ein Verfahren, das in einer Fallstudie mit 10.000 PS funktioniert, muss nicht zwingend ohne weiteres auf 10 Millionen PS skaliert werden können. Die Entwicklung von **Big-Data-fähigen Workflows** (z.B. verteilte Berechnungen in der Cloud, effiziente Indexierung für Nachbarschaftssuche etc.) ist ein praktisches aber essentielles Forschungsfeld, um die Methoden in großem Maßstab einsetzbar zu machen. Gleiches gilt für die Aktualisierung: Stadtmonitoring erfordert evtl. regelmäßige Updates der PS und deren Zuordnung – Algorithmen sollten inkrementell arbeiten können, statt immer alles von Grund auf neu zu berechnen.

Zusammengefasst existieren in der PS-Zuordnung zu Bauwerken noch zahlreiche *Forschungsfragen*, von der Verbesserung der physikalischen Positionsbestimmung über die Handhabung komplexer städtischer Situationen bis hin zur Einbindung moderner KI unter Wahrung der Interpretierbarkeit. Die Fortschritte von 2020–2025 haben wichtige Grundlagen gelegt (z. B. hybride Distanzmetriken, adaptive Konturanpassung), doch zur **flächendeckenden, vollautomatischen und verlässlichen Umsetzung** gibt es noch Hürden, die weitere interdisziplinäre Arbeit erfordern.

## Empfehlungen für geeignete Methoden

Basierend auf dem aktuellen Stand lassen sich für die Praxis – etwa ein städtisches Deformationsmonitoring – folgende **empfehlenswerte Vorgehensweisen** ableiten:

1. **Kombinierte Geometrie- und Cluster-Methode:** Die vielversprechendste Strategie ist eine *Kombination* der Stärken beider Welten. Empfohlen wird, zunächst alle PS grob mittels **Gebäudepolygonen mit Höhen-Puffer** einem Objekt zuzuordnen (z. B. nach Hu et al. 2024 <sup>3</sup>). Dadurch wird ein Großteil der Punkte schon richtig gruppiert, mit minimalem Aufwand. Anschließend kann innerhalb jedes so gefundenen Gebäude-Clusters eine **feinere Clustering nach Zeitreihenmustern** erfolgen (nach dem Prinzip Schneider et al. 2021 <sup>28</sup>). So würden z. B. alle PS, die einem Hochhaus zugeordnet sind, nochmals analysiert – vielleicht ergeben sich zwei Cluster, was andeutet, dass unterschiedliche Gebäudeteile unterschiedliche Bewegungen zeigen. Diese Kombination liefert sowohl *globale Kohärenz* (kein Cluster enthält Punkte völlig verschiedener Gebäude) als auch *lokale Sensitivität* (erkennbare interne Differenzen werden aufgedeckt). In der Praxis ist dies umsetzbar mit frei verfügbaren Tools: GIS für den ersten Schritt, Python (UMAP + DBSCAN) für den zweiten. Interpretierbarkeit und Genauigkeit sind hoch, der Rechenaufwand bleibt moderat, da das Clustering segmentiert nach Gebäuden geschieht. Für die meisten Anwendungsfälle – z. B. kommunales Subsidenz-Monitoring – dürfte dieser zweistufige Ansatz eine **ausgewogene Balance** bieten.
2. **Adaptive Kontur-Zuordnung (bei limitierten Daten):** Stehen keine detaillierten Zeitreihen oder personellen Ressourcen für komplexe Analysen zur Verfügung, sollte zumindest ein **adaptives geometrisches Matching** durchgeführt werden. Die Methode von Hu et al. (2024) kann hier als Vorlage dienen: Nutzung verfügbarer Gebäudeumrisse (etwa aus OSM) und deren *Adaptive Pufferung nach Höhe*, dann Zuordnung per nächster Distanz <sup>3</sup>. Dieser Ansatz ist relativ leicht implementierbar und **bereits mit offenen Daten und Tools machbar**. Die Genauigkeit ist deutlich höher als bei simpler Polygonmethode – in Testfällen ~30 % mehr korrekte Zuordnungen <sup>16</sup> – und er ist robust gegenüber Ausreißern, da er statistisch mehr PS einem Gebäude zuordnet. Für Städte, die z. B. einen Grundstock an Sentinel-1 PS-Daten haben und schnell eine Zuordnung brauchen (etwa zur Risikoübersicht), bietet sich diese pragmatische Lösung an. Wichtig ist, aktuelle Gebäudedaten zu verwenden und ggf. die Parameter (Buffer-

Breite) an lokale Verhältnisse (Gebäudehöhen, Orbit-Geometrie) anzupassen. Diese Methode liefert eine gute **Baseline**, die bei Bedarf später um fortgeschrittene Schritte ergänzt werden kann.

3. **Zeitreihen-Clustering als Detailanalyse:** Für Projekte mit dem Fokus auf **komplizierte Bewegungsmuster** oder wissenschaftliche Fragestellungen (z.B. Erkennung abnormaler Verformungen) empfiehlt sich der **Einsatz von Clusteranalysen auf den PS-Zeitreihen**. Insbesondere in Gebieten mit bekanntermaßen unterschiedlichen Einflüssen (etwa Teilsenkungen durch Baustellen vs. restliche stabile Umgebung) kann so automatisch zwischen den Effekten getrennt werden. Hierfür existiert auch direkt nutzbarer Code – z.B. der GitHub-Prototyp von Guiduzzi et al. (2025) zur interpretierbaren PS-Clustering <sup>9</sup> <sup>38</sup> – der als Ausgangspunkt dienen kann. Diese Methode sollte idealerweise mit Vorwissen kombiniert werden: Wenn z.B. grobe Gebäudeumrisse bekannt sind, kann man Clustering ergebnisgesteuert einsetzen (z.B. prüfen, ob die gefundenen Cluster mit Gebäuden korrespondieren). In einer praktischen Umsetzung könnte man etwa alle PS innerhalb eines Stadtviertels mit HDBSCAN clustern lassen und dann jedes Cluster einem Gebäudepolygon zuordnen (z.B. anhand Mehrheit der Punkte). So identifiziert man z.B. auch Objekte, die sich bewegen, *ohne* sie vorher explizit zu kennen – ein Vorteil, wenn die Gebäudedaten lückenhaft sind (z.B. informelle Siedlungen). Diese **datengetriebene Methode** erfordert mehr Rechenleistung und Experteneinsatz zur Interpretation, bietet aber tiefere Einsichten, etwa um *frühzeitig Schadensindikatoren* zu entdecken (z.B. ein Teilcluster an einem Gebäude mit zunehmender Absenkung).
4. **Einsatz von 3D-Stadtmodellen wo verfügbar:** Wenn für ein Untersuchungsgebiet hochwertige 3D-Informationen vorliegen (z.B. eine CityGML-LoD2 Datei oder ein Laserscan der Innenstadt), sollte dies genutzt werden, um die PS-Zuordnung zu verfeinern. In der Praxis könnte man den oben empfohlenen zweistufigen Ansatz noch erweitern: Nach der Zuordnung könnten PS-Cluster **mit dem 3D-Modell abgeglichen** werden, um z.B. festzustellen, ob die räumliche Verteilung der PS zur Gebäudegeometrie passt (siehe Schunert & Soergel 2016 mit ICP <sup>19</sup>). Oder man könnte einzelne fehlzugeordnete Punkte identifizieren und entfernen – z.B. ein PS-Cluster liegt eigentlich 5 m neben der Gebäudefassade im Luftraum, was auf einen Reflex von einer anderen Struktur hinweist. Ein 3D-Abgleich liefert eine **Qualitätskontrolle**: Überall dort, wo PS nicht gut ins Modell projizieren, ist Vorsicht geboten. Für städtische Behörden, die bereits in Richtung **digitaler Zwilling** arbeiten, kann die Integration der PS-Deformationen in das BIM-Modell (Building Information Modeling) einen großen Mehrwert bieten <sup>39</sup>. Die Empfehlung lautet daher: Wo 3D-Daten vorhanden sind, sollten sie zur *Ergebniskosmetik und -prüfung* auf PS-Zuordnungen angesetzt werden. Aufgrund des höheren Aufwands ist dies als optionaler Schritt für kritische Bereiche oder zur endgültigen Verifikation sinnvoll.
5. **Langzeit-Monitoring und automatisierte Validierung:** Im Rahmen einer dauerhaften Überwachung (z.B. jährlich fortgeschriebene PS-Analysen) sollte ein Mechanismus etabliert werden, der **Änderungen in der Zuordnung** erkennt. Die Empfehlung ist, eine Art *Monitoringskript* zu entwickeln, das neue PS-Punkte mit den bestehenden Objektgruppen vergleicht und Abweichungen meldet (etwa: „neue PS-Gruppe entstanden, die keinem bekannten Gebäude zugeordnet ist“ oder „PS von Gebäude X zeigen plötzlich zwei unterschiedliche Bewegungsmuster“). Dies lässt sich durch fortlaufendes Clustering mit Konsistenzprüfung erreichen. So eine Automation ermöglicht es, **offene Fragestellungen** (z.B. ob ein Gebäudeteil sich ab einem bestimmten Zeitpunkt anders verhält) frühzeitig zu erkennen und gezielt nachzuforschen. Zudem kann es als Validierung dienen: Wenn ein Algorithmus von Jahr zu Jahr dramatisch wechselnde Zuordnungen liefert, stimmt etwas nicht – idealerweise

sollten PS über moderate Zeiträume konsistent demselben Objekt zugeordnet bleiben, sofern keine externen Veränderungen eintreten.

Abschließend sei betont, dass die **Methodenauswahl** stets von den verfügbaren Daten und dem Ziel abhängt. Für eine schnelle, großflächige Risikokartierung einer Stadt wird man eher den pragmatischen geometrischen Ansatz (Punkt-zu-Polygon) mit leichten Verbesserungen (adaptive Buffer) wählen – dieser ist offen verfügbar, schnell und liefert brauchbare Resultate <sup>16</sup>. Für detaillierte wissenschaftliche Untersuchungen einzelner Bauwerke oder kritischer Infrastrukturen kann man mit aufwendigeren Clustering- und 3D-Methoden in die Tiefe gehen. **Tabelle 1** in der Bewertungssektion zeigte bereits eine Rangfolge nach Praxistauglichkeit, die hier als Empfehlung zusammengefasst werden kann: Am praxisgerechtesten sind Verfahren, die *offene Datenquellen nutzen und robuste, interpretierbare Ergebnisse liefern*, also insbesondere adaptive 2D-Zuordnung und (wo nötig) ergänzendes Clustering. Hochpräzise 3D-Methoden folgen in spezialisierten Situationen. Rein datengesteuerte (KI-)Ansätze ohne Einbindung von Stadtplandaten sind momentan eher ergänzend zu betrachten, da ihre Verlässlichkeit im dichten urbanen Raum begrenzt ist. Nicht zuletzt sollte bei jeder gewählten Methode genügend Zeit für die **Validierung** eingeplant werden – sei es durch Expertenblick oder Cross-Checks mit anderen Daten – um sicherzustellen, dass die Zuordnung der PS-Punkte zu Gebäuden belastbar ist und als Grundlage für weitere Entscheidungen (z. B. Bauwerksüberwachung, Gefahreinschätzung) dienen kann.

**Quellen:** Die obigen Empfehlungen stützen sich auf Erkenntnisse aktueller Studien und Vergleiche <sup>3</sup> <sup>16</sup> <sup>27</sup> <sup>14</sup>, sowie auf eine Synthese der Vor- und Nachteile der in 2020–2025 publizierten Methoden. Durch Kombination dieser Best Practices kann für unterschiedliche Anwendungsszenarien eine geeignete Vorgehensweise ausgewählt werden.

---

<sup>1</sup> <sup>2</sup> <sup>3</sup> <sup>4</sup> <sup>16</sup> <sup>17</sup> <sup>18</sup> <sup>19</sup> <sup>20</sup> <sup>21</sup> <sup>22</sup> <sup>23</sup> <sup>24</sup> <sup>25</sup> <sup>26</sup> <sup>29</sup> <sup>30</sup> <sup>31</sup> <sup>34</sup> <sup>37</sup> Correcting the Location Error of Persistent Scatterers in an Urban Area Based on Adaptive Building Contours Matching: A Case Study of Changsha

<https://www.mdpi.com/2072-4292/16/9/1543>

<sup>5</sup> <sup>39</sup> ISPRS-Annals - MATCHING PERSISTENT SCATTERER CLUSTERS TO BUILDING ELEMENTS IN MESH REPRESENTATION

<https://isprs-annals.copernicus.org/articles/V-3-2022/123/2022/>

<sup>6</sup> <sup>7</sup> [isprs-annals.copernicus.org](https://isprs-annals.copernicus.org)

<https://isprs-annals.copernicus.org/articles/X-1-W1-2023/869/2023/isprs-annals-X-1-W1-2023-869-2023.pdf>

<sup>8</sup> <sup>27</sup> <sup>28</sup> <sup>36</sup> [isprs-annals.copernicus.org](https://isprs-annals.copernicus.org)

<https://isprs-annals.copernicus.org/articles/V-3-2021/65/2021/isprs-annals-V-3-2021-65-2021.pdf>

<sup>9</sup> <sup>38</sup> Interpretable clustering of PS-InSAR time series for ground deformation detection - ScienceDirect

<https://www.sciencedirect.com/science/article/pii/S0098300425001098>

<sup>10</sup> Persistent Scatterer Pixel Selection Method Based on Multi ... - MDPI

<https://www.mdpi.com/2072-4292/17/19/3319>

<sup>11</sup> Detecting change points in time series of inSAR persistent scatterers ...

<https://link.springer.com/article/10.1007/s12518-025-00621-x>

<sup>12</sup> <sup>13</sup> <sup>14</sup> <sup>15</sup> <sup>33</sup> Linking Persistent Scatterers to the Built Environment using Ray-Tracing on Urban Models

[https://filipbiljecki.com/publications/2019\\_tgrs\\_ps3d.pdf](https://filipbiljecki.com/publications/2019_tgrs_ps3d.pdf)

32 an open global and complete dataset of building polygons, heights ...

<https://essd.copernicus.org/articles/17/6647/2025/>

35 Graph Matching for the Registration of Persistent Scatterers to ...

<https://ui.adsabs.harvard.edu/abs/2016ISPAIII7..195S/abstract>